

Търсене и извличане на информация. Приложение на дълбоко машинно обучение

Стоян Михов



Лекция 6: Принципен компонентен анализ (PCA). Влагане на думи и
документи в гъсто нискомерно векторно пространство.

План на лекцията

- 1. Формалности за курса (5 мин)**
2. Интуиция за принципния компонентен анализ (10 мин)
3. Смятане с вектори и матрици (15 мин)
4. Свойства на ковариационната матрица (15 мин)
5. Задача за намиране на принципните компоненти (25 мин)
6. Влагане на думи и контексти в нискомерно гъсто векторно пространство и латентен семантичен анализ (10 мин)
7. Семантично пространствени релации (10 мин)

Формалности

- В близките дни ще бъде публикувано първото домашно задание в Мудъл.
- Шестата лекция се базира на глава 18 от първия учебник и секция 10.4 от втория учебник.


План на лекцията

1. Формалности за курса (5 мин)
- 2. Интуиция за принципния компонентен анализ (10 мин)**
3. Смятане с вектори и матрици (15 мин)
4. Свойства на ковариационната матрица (15 мин)
5. Задача за намиране на принципните компоненти (25 мин)
6. Влагане на думи и контексти в нискомерно гъсто векторно пространство и латентен семантичен анализ (10 мин)
7. Семантично пространствени релации (10 мин)


Влагането на думи във векторното пространство на контекстите

- Контекстът на дадена дума са думите, които са около нея – в рамките на параграф, изречение или фиксиран по размер прозорец.
- На всяка дума съпоставяме вектора от свързванията на думата с всеки от контекстите.
- Размерността на пространството е огромна, което води до изчислителни трудности.
- **Цел:** Да намерим влагане на векторите в нискомерно гъсто векторно пространство, което възможно най-добре да отразява разстоянията в многомерното контекстно пространство.



Интуитивна представа за принципен компонентен анализ



Интуитивна представа за принципен компонентен анализ



Интуитивна представа за принципен компонентен анализ



Основна идея

- Ще използваме техниката на принципния компонентен анализ за да намерим нискомерен базис от ортогонални вектори – размерността обикновено е между 25 и 1000.
- В този базис разстоянията между векторите ще искаеме да са максимално близки до съответните разстояния в многомерното пространство.
- Направленията в новия базис ще съответстват на линейни комбинации от оригиналните базисни вектори определени от контекстите.
- Новите вектори ще бъдат “гъсти” – почти няма да има нулеви компоненти.
- Намалянето на размерността може да доведе до намаляне на шума и до постигане на по-висока прецизност.

План на лекцията

1. Формалности за курса (5 мин)
2. Интуиция за принципния компонентен анализ (10 мин)
- 3. Смятане с вектори и матрици (15 мин)**
4. Свойства на ковариационната матрица (15 мин)
5. Задача за намиране на принципните компоненти (25 мин)
6. Влагане на думи и контексти в нискомерно гъсто векторно пространство и латентен семантичен анализ (10 мин)
7. Семантично пространствени релации (10 мин)

Означения на вектори и матрици

- Матриците ще бележим с главни удебелени букви – $\mathbf{W}, \mathbf{V}, \mathbf{A}, \mathbf{B}$, единична матрица – \mathbf{I} .
 $\mathbf{W}_{i,j}$ – елементът на ред i , стълб j в матрицата \mathbf{W} .
 $\mathbf{W}_{i,\cdot}$ – вектор ред i на матрицата \mathbf{W} .
 $\mathbf{W}_{\cdot,j}$ – вектор стълб j на матрицата \mathbf{W} .
- Векторите ще бележим с малки удебелени букви – $\mathbf{u}, \mathbf{v}, \mathbf{x}, \mathbf{y}$.
 \mathbf{u}_i – i -тия елемент на \mathbf{u} .

- Ако не е указано друго, ще подразбираме вектор стълбове. Т.е. $\mathbf{u} = \begin{bmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \vdots \\ \mathbf{u}_n \end{bmatrix}$.
- Векторите може да разглеждаме като матрици – $\mathbf{u} \in \mathbb{R}^{n \times 1}$.
- С $\mathbf{1}_n \in \mathbb{R}^n$ ще бележим вектор, състоящ се само от единици. С $\mathbf{1}_{n \times m} \in \mathbb{R}^{n \times m}$ ще бележим матрица, състояща се само от единици.

Произведения на матрици и вектори

- **Произведение на матрици:** Нека $\mathbf{A} \in \mathbb{R}^{n \times m}$, $\mathbf{B} \in \mathbb{R}^{m \times k}$, тогава $\mathbf{C} = \mathbf{AB}$, ако $\mathbf{C} \in \mathbb{R}^{n \times k}$ и $\mathbf{C}_{i,j} = \sum_{l=1}^m \mathbf{A}_{i,l} \mathbf{B}_{l,j}$.
- **Произведение на матрица с вектор:**
Нека $\mathbf{A} \in \mathbb{R}^{n \times m}$, $\mathbf{x} \in \mathbb{R}^{m \times 1}$, тогава $\mathbf{y} = \mathbf{Ax}$, ако $\mathbf{y} \in \mathbb{R}^{n \times 1}$ и $\mathbf{y}_i = \sum_{l=1}^m \mathbf{A}_{i,l} \mathbf{x}_l$.
Нека $\mathbf{u} \in \mathbb{R}^{n \times 1}$, тогава вектора ред $\mathbf{v} = \mathbf{u}^\top \mathbf{A}$, ако $\mathbf{v} \in \mathbb{R}^{1 \times m}$ и $\mathbf{v}_i = \sum_{l=1}^n \mathbf{u}_l \mathbf{A}_{l,i}$.
- **Скаларно произведение** на два вектора: Нека $\mathbf{u}, \mathbf{v} \in \mathbb{R}^{n \times 1}$ тогава $\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^\top \mathbf{v} = \sum_{l=1}^n \mathbf{u}_l \mathbf{v}_l$.
- **Квадратична форма:** Нека $\mathbf{A} \in \mathbb{R}^{n \times n}$, $\mathbf{x} \in \mathbb{R}^{n \times 1}$ тогава $\mathbf{x}^\top \mathbf{Ax} = \sum_{i=1}^n \sum_{j=1}^n \mathbf{x}_i \mathbf{A}_{i,j} \mathbf{x}_j$.
- **Диадно (тензорно, външно) произведение** на два вектора: Нека $\mathbf{x} \in \mathbb{R}^{n \times 1}$, $\mathbf{y} \in \mathbb{R}^{m \times 1}$, тогава $\mathbf{x} \otimes \mathbf{y} = \mathbf{xy}^\top = \mathbf{C}$, ако $\mathbf{C} \in \mathbb{R}^{n \times m}$ и $\mathbf{C}_{i,j} = \mathbf{x}_i \mathbf{y}_j$.
- **Поелементно произведение** на вектори или матрици: Ако $\mathbf{x} \in \mathbb{R}^{n \times 1}$, $\mathbf{y} \in \mathbb{R}^{n \times 1}$, то $\mathbf{x} \odot \mathbf{y} \in \mathbb{R}^{n \times 1}$ и $(\mathbf{x} \odot \mathbf{y})_i = \mathbf{x}_i \mathbf{y}_i$. Ако $\mathbf{A} \in \mathbb{R}^{n \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times m}$, то $\mathbf{A} \odot \mathbf{B} \in \mathbb{R}^{n \times m}$ и $(\mathbf{A} \odot \mathbf{B})_{i,j} = \mathbf{A}_{i,j} \mathbf{B}_{i,j}$.

Градиент и Якобиан

Нека $f : \mathbb{R}^n \rightarrow \mathbb{R}$. **Градиент** на f наричаме вектора: $\nabla_{\mathbf{x}} f(\mathbf{x}) = \frac{\partial}{\partial \mathbf{x}} f(\mathbf{x}) =$

$$\begin{bmatrix} \frac{\partial}{\partial x_1} f(\mathbf{x}) \\ \frac{\partial}{\partial x_2} f(\mathbf{x}) \\ \vdots \\ \frac{\partial}{\partial x_n} f(\mathbf{x}) \end{bmatrix}$$

$$\left(\frac{\partial}{\partial \mathbf{x}} f(\mathbf{x}) \right)_i = \frac{\partial}{\partial x_i} f(\mathbf{x})$$

• Нека $\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$, т.е. $\mathbf{f}(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})) \in \mathbb{R}^m$,

Якобиан на \mathbf{f} наричаме матрицата:

$$\nabla_{\mathbf{x}} \mathbf{f}(\mathbf{x}) = \frac{\partial}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}) = \begin{bmatrix} \frac{\partial}{\partial x_1} f_1(\mathbf{x}) & \dots & \frac{\partial}{\partial x_n} f_1(\mathbf{x}) \\ \vdots & \ddots & \vdots \\ \frac{\partial}{\partial x_1} f_m(\mathbf{x}) & \dots & \frac{\partial}{\partial x_n} f_m(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} \nabla_{\mathbf{x}} f_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} f_m(\mathbf{x})^\top \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

$$\left(\frac{\partial}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}) \right)_{i,j} = \frac{\partial}{\partial x_j} f_i(\mathbf{x})$$

Свойства

- Нека $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^{n \times 1}$. Тогава: $\frac{\partial}{\partial \mathbf{x}} \mathbf{A}\mathbf{x} = \mathbf{A} \in \mathbb{R}^{m \times n}$
- Нека $\mathbf{x} \in \mathbb{R}^{n \times 1}$. Тогава $\frac{\partial}{\partial \mathbf{x}} \mathbf{x} = \frac{\partial}{\partial \mathbf{x}} \mathbf{I}\mathbf{x} = \mathbf{I}$.
- Нека $\mathbf{u}, \mathbf{v} \in \mathbb{R}^{n \times 1}$. Тогава $\frac{\partial}{\partial \mathbf{u}} \mathbf{u}^\top \mathbf{v} = \mathbf{v}$, $\frac{\partial}{\partial \mathbf{v}} \mathbf{u}^\top \mathbf{v} = \mathbf{u}$.
- Нека $\mathbf{f}, \mathbf{g} \in \mathbb{R}^n \rightarrow \mathbb{R}^m$. Тогава
$$\frac{\partial}{\partial \mathbf{x}} (\mathbf{f}(\mathbf{x})^\top \mathbf{g}(\mathbf{x})) = \left(\frac{\partial}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}) \right)^\top \mathbf{g}(\mathbf{x}) + \mathbf{f}(\mathbf{x})^\top \left(\frac{\partial}{\partial \mathbf{x}} \mathbf{g}(\mathbf{x}) \right)$$
- Нека $\mathbf{A} \in \mathbb{R}^{n \times n}$, $\mathbf{x} \in \mathbb{R}^{n \times 1}$. Тогава $\frac{\partial}{\partial \mathbf{x}} \mathbf{x}^\top \mathbf{A}\mathbf{x} = (\mathbf{A} + \mathbf{A}^\top)\mathbf{x}$.

План на лекцията

1. Формалности за курса (5 мин)
2. Интуиция за принципния компонентен анализ (10 мин)
3. Смятане с вектори и матрици (15 мин)
- 4. Свойства на ковариационната матрица (15 мин)**
5. Задача за намиране на принципните компоненти (25 мин)
6. Влагане на думи и контексти в нискомерно гъсто векторно пространство и латентен семантичен анализ (10 мин)
7. Семантично пространствени релации (10 мин)

Ковариационна матрица

- Ковариационна матрица на вектор от случайни величини $\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{bmatrix}$ е матрица

$\mathbb{R}^{N \times N}$, която означаваме с $\mathbf{C}[\mathbf{X}]$ и дефинираме като:

$$\mathbf{C}[\mathbf{X}] = \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top],$$

$$\text{т.е. } \mathbf{C}[\mathbf{X}]_{i,j} = \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])^\top] = \text{Cov}(X_i, X_j)$$

Свойство:

- $\mathbf{C}[\mathbf{X}] = \mathbb{E}[\mathbf{X}\mathbf{X}^\top] - \mathbb{E}[\mathbf{X}]\mathbb{E}[\mathbf{X}]^\top$
 - защото: $\mathbf{C}[\mathbf{X}]_{i,j} = \text{Cov}(X_i, X_j) = \mathbb{E}[X_i X_j] - \mathbb{E}[X_i]\mathbb{E}[X_j]$

Забележка: $\mathbf{X}\mathbf{X}^\top = \mathbf{X} \otimes \mathbf{X}$

- **Свойство**: Нека $u, v \in \mathbb{R}^n$. Тогава: $(u \cdot v)^2 = v^\top(u \otimes u)v = v^\top(uu^\top)v$
- доказателство:

$$(u \cdot v)^2 = (u^\top v)(u^\top v) = \left(\sum_{i=1}^n u_i v_i \right) \left(\sum_{j=1}^n u_j v_j \right) = \sum_{i=1}^n \sum_{j=1}^n u_i v_i u_j v_j$$

$$v^\top(uu^\top)v = v^\top((uu^\top)v) = \sum_{i=1}^n v_i ((uu^\top)v)_i = \sum_{i=1}^n v_i \sum_{j=1}^n (u_i u_j) v_j = \sum_{i=1}^n \sum_{j=1}^n u_i v_i u_j v_j$$

- **Дефиниция**: Матрицата (определяща квадратична форма) $A \in \mathbb{R}^{n \times n}$ наричаме положително дефинитна, ако за всеки вектор $v \in \mathbb{R}^n$ е изпълнено: $v^\top A v \geq 0$.
- **Твърдение**: Всяка ковариационна матрица е симетрична и положително дефинитна.
- **Доказателство**:

$$\mathbf{C}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top] = \sum_{\mathbf{x} \in \mathbf{X}(\Omega)} \Pr[\mathbf{X} = \mathbf{x}] (\mathbf{x} - \mathbb{E}[\mathbf{X}])(\mathbf{x} - \mathbb{E}[\mathbf{X}])^\top$$

$$\begin{aligned} v^\top \mathbf{C}(\mathbf{X}) v &= \sum_{\mathbf{x} \in \mathbf{X}(\Omega)} \Pr[\mathbf{X} = \mathbf{x}] v^\top (\mathbf{x} - \mathbb{E}[\mathbf{X}])(\mathbf{x} - \mathbb{E}[\mathbf{X}])^\top v = \\ &= \sum_{\mathbf{x} \in \mathbf{X}(\Omega)} \Pr[\mathbf{X} = \mathbf{x}] ((\mathbf{x} - \mathbb{E}[\mathbf{X}]) \cdot v)^2 \geq 0 \end{aligned}$$

- **Теорема:** (от курса по Линейна алгебра) Нека $A \in \mathbb{R}^{n \times n}$ е симетрична матрица ($A^T = A$). Тогава:

1. Всички собствени стойности на A – корените на характеристичното уравнение $|A - \lambda I| = 0$ – са реални числа.
2. Съществува ортонормиран базис $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n \in \mathbb{R}^n$ от собствени вектори на A , така че:

- $A\mathbf{e}_i = \lambda_i \mathbf{e}_i$

$$A = T\Lambda T^{-1}, \text{ където } T = [\mathbf{e}_1 \ \mathbf{e}_2 \ \dots \ \mathbf{e}_n] \text{ и } \Lambda = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & & \ddots & \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$$

- **Забележка:** Матрицата T е ортогонална: $T^{-1} = T^T$
- **Твърдение:** Ако $A \in \mathbb{R}^{n \times n}$ е симетрична и положително дефинитна матрица то всички собствени стойности на A са реални неотрицателни числа.
- **Доказателство:** $\lambda = \mathbf{e}^T \lambda \mathbf{e} = \mathbf{e}^T (A\mathbf{e}) \geq 0$

План на лекцията

1. Формалности за курса (5 мин)
2. Интуиция за принципния компонентен анализ (10 мин)
3. Смятане с вектори и матрици (15 мин)
4. Свойства на ковариационната матрица (15 мин)
- 5. Задача за намиране на принципните компоненти (25 мин)**
6. Влагане на думи и контексти в нискомерно гъсто векторно пространство и латентен семантичен анализ (10 мин)
7. Семантично пространствени релации (10 мин)

Постановка на задачата

- Дадени са S вектора $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(S)} \in \mathbb{R}^N$ в N мерно пространство и число $M \in \mathbb{N}^+, M < N$. Можем да разглеждаме векторите $\mathbf{x}^{(i)}$ като S наблюдения на вектор \mathbf{X} от N случаини величини.
- Търсим ортонормиран базис $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_N$ в \mathbb{R}^N , и числа $b_{M+1}, b_{M+2}, \dots, b_N$, така че ако
 - векторите $\mathbf{x}^{(i)}$ се представят в новата координатна система като $\mathbf{x}^{(i)} = \sum_{j=1}^N y_j^{(i)} \mathbf{e}_j$, където $y_j^{(i)} = \mathbf{x}^{(i)} \cdot \mathbf{e}_j$, и
 - $\hat{\mathbf{x}}^{(i)} = \sum_{j=1}^M y_j^{(i)} \mathbf{e}_j + \sum_{j=M+1}^N b_j \mathbf{e}_j$ са проекции на $\mathbf{x}^{(i)}$ върху M мерна хиперравнина
 - Тогава $\varepsilon^2 = \frac{1}{S} \sum_{i=1}^S \|\mathbf{x}^{(i)} - \hat{\mathbf{x}}^{(i)}\|^2$ е минимално.

$$\cdot \varepsilon^2 = \frac{1}{S} \sum_{i=1}^S \|\mathbf{x}^{(i)} - \hat{\mathbf{x}}^{(i)}\|^2 = \frac{1}{S} \sum_{i=1}^S \sum_{j=M+1}^N (\mathbf{x}^{(i)} \cdot \mathbf{e}_j - b_j)^2$$

- За да намерим b_j търсим къде се нулират производните:

$$\cdot \frac{\partial}{\partial b_j} \varepsilon^2 = \frac{1}{S} \sum_{i=1}^S -2(\mathbf{x}^{(i)} \cdot \mathbf{e}_j - b_j) = 0$$

$$\cdot b_j = \frac{1}{S} \sum_{i=1}^S \mathbf{x}^{(i)} \cdot \mathbf{e}_j$$

- Можем да разглеждаме компонентите на векторите $\mathbf{x}^{(i)}$ като наблюдения на случайните величини $\mathbf{X}^{(i)}$ еднакво разпределени с \mathbf{X} . В такъв случай:
 $b_j = \mathbb{E}_S[\mathbf{X} \cdot \mathbf{e}_j] = \mathbb{E}_S[Y_j]$, където разглеждаме случайна величина $Y_j = \mathbf{X} \cdot \mathbf{e}_j$ с наблюдения $y_j^{(i)} = \mathbf{x}^{(i)} \cdot \mathbf{e}_j$.
- **Интуитивно**: Заменяме измеренията, които премахваме, със средните стойности по тези измерения.

- В такъв случай, като заместим в ε^2 получаваме:

$$\begin{aligned}\varepsilon^2 &= \frac{1}{S} \sum_{i=1}^S \sum_{j=M+1}^N (\mathbf{x}^{(i)} \cdot \mathbf{e}_j - b_j)^2 = \sum_{j=M+1}^N \frac{1}{S} \sum_{i=1}^S (y_j^{(i)} - \mathbb{E}_S[Y_j])^2 = \\ &= \sum_{j=M+1}^N \mathbb{E}_S[(Y_j - \mathbb{E}_S[Y_j])^2]\end{aligned}$$

- Заместваме и получаваме:

$$\begin{aligned}\varepsilon^2 &= \sum_{j=M+1}^N \mathbb{E}_S[(Y_j - \mathbb{E}_S[Y_j])^2] = \sum_{j=M+1}^N \mathbb{E}_S[(\mathbf{X} \cdot \mathbf{e}_j - \mathbb{E}_S[\mathbf{X} \cdot \mathbf{e}_j])^2] = \\ &= \sum_{j=M+1}^N \mathbb{E}_S[((\mathbf{X} - \mathbb{E}_S[\mathbf{X}]) \cdot \mathbf{e}_j)^2] = \sum_{j=M+1}^N \mathbb{E}_S[\mathbf{e}_j^\top ((\mathbf{X} - \mathbb{E}_S[\mathbf{X}]) (\mathbf{X} - \mathbb{E}_S[\mathbf{X}])^\top) \mathbf{e}_j] = \\ &= \sum_{j=M+1}^N \mathbf{e}_j^\top \mathbb{E}_S[((\mathbf{X} - \mathbb{E}_S[\mathbf{X}]) (\mathbf{X} - \mathbb{E}_S[\mathbf{X}])^\top)] \mathbf{e}_j = \sum_{j=M+1}^N \mathbf{e}_j^\top \mathbf{C}_S(\mathbf{X}) \mathbf{e}_j\end{aligned}$$

- Търсим ортонормиран базис \mathbf{e}_j , който минимизира ε^2 . Ще използваме множители на Лагранж, за да си осигурим $\mathbf{e}_j \cdot \mathbf{e}_j = 1$. Дефинираме $N - M$ функции: $g_j(\mathbf{e}_j) = \mathbf{e}_j \cdot \mathbf{e}_j$.

$$\begin{aligned} \frac{\partial}{\partial \mathbf{e}_j} \left(\varepsilon^2 - \sum_{k=M+1}^N \lambda_k (g_k(\mathbf{e}_k) - 1) \right) &= \frac{\partial}{\partial \mathbf{e}_j} \left(\sum_{k=M+1}^N \mathbf{e}_k^\top \mathbf{C}_S(\mathbf{X}) \mathbf{e}_k - \sum_{k=M+1}^N \lambda_k (\mathbf{e}_k \cdot \mathbf{e}_k - 1) \right) = \\ &= (\mathbf{C}_S(\mathbf{X}) + \mathbf{C}_S(\mathbf{X})^\top) \mathbf{e}_j - 2\lambda_j \mathbf{e}_j = 2\mathbf{C}_S(\mathbf{X}) \mathbf{e}_j - 2\lambda_j \mathbf{e}_j = 0 \end{aligned}$$

- Така получаваме: $\mathbf{C}_S(\mathbf{X}) \mathbf{e}_j = \lambda_j \mathbf{e}_j$

$$\frac{\partial}{\partial \lambda_j} \left(\varepsilon^2 - \sum_{k=M+1}^N \lambda_k (g_k(\mathbf{e}_k) - 1) \right) = \mathbf{e}_j \cdot \mathbf{e}_j - 1 = 0$$

- Т.е. $\mathbf{e}_j \cdot \mathbf{e}_j = 1$

Решение

- Ковариационната матрица $\mathbf{C}_S(\mathbf{X})$ е симетрична и положително дефинитна. Следователно на нея съответстват N ортогонални собствени вектори със съответни положителни собствени стойности.
- От нулирането на производните следва, че необходимо условие за търсеният базис е да се състои от собствени вектори на $\mathbf{C}_S(\mathbf{X})$. В такъв случай:
$$\varepsilon^2 = \sum_{j=M+1}^N \mathbf{e}_j^\top \mathbf{C}_S(\mathbf{X}) \mathbf{e}_j = \sum_{j=M+1}^N \mathbf{e}_j^\top \lambda_j \mathbf{e}_j = \sum_{j=M+1}^N \lambda_j.$$
- Тъй като всички собствени стойности са неотрицателни, минималната стойност за ε^2 се получава, като за $\lambda_{M+1}, \dots, \lambda_N$ се изберат най-малките $N - M$ собствени стойности.
- Избираме базисните вектори $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_M$, така че на тях да им съответстват най-големите M собствени стойности.

План на лекцията

1. Формалности за курса (5 мин)
2. Интуиция за принципния компонентен анализ (10 мин)
3. Смятане с вектори и матрици (15 мин)
4. Свойства на ковариационната матрица (15 мин)
5. Задача за намиране на принципните компоненти (25 мин)
6. **Влагане на думи и контексти в нискомерно гъсто векторно пространство и латентен семантичен анализ (10 мин)**
7. Семантично пространствени релации (10 мин)

Влагане – проекция на контекстите

- Нека $\mathbf{X} \in \mathbb{R}^{|V| \times S}$ е терм / контекст матрица. На всеки терм съответства ред от матрицата със свързванията на терма към съответните S контекста. На всеки контекст съответства стълб от матрицата със свързванията на контекста към съответните $|V|$ терма.
- Нека предварително сме центрирали наблюденията за термовете около 0. Т.е. $\mathbb{E}[\mathbf{X}_{j,\cdot}] = 0$ за $j = 1, 2, \dots, |V|$.
- Нека първите M принципни компоненти на $\mathbf{X}\mathbf{X}^\top = \mathbf{C}(\mathbf{X}) \in \mathbb{R}^{|V| \times |V|}$ са ортонормирани вектори $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_M \in \mathbb{R}^{|V|}$.
- Дефинираме матрицата $U_M = [\mathbf{e}_1 \quad \mathbf{e}_2 \quad \dots \quad \mathbf{e}_M] \in \mathbb{R}^{|V| \times M}$.
- Проекцията на контекстите в M -мерно пространство получаваме:
 $\tilde{\mathbf{X}}_M = U_M^\top \mathbf{X} \in \mathbb{R}^{M \times S}$. На всеки стълб (контекст) в $\tilde{\mathbf{X}}_M$ съпоставяме M -мерен вектор.

Влагане – проекция на термовете

- Нека $\mathbf{X} \in \mathbb{R}^{|V| \times S}$ е терм / контекст матрица. На всеки терм съответства ред от матрицата със свързванията на терма към съответните S контекста. На всеки контекст съответства стълб от матрицата със свързванията на контекста към съответните $|V|$ терма.
- Нека предварително сме центрирали наблюденията за контекстите около 0. Т.е. $\mathbb{E}[\mathbf{X}_{\bullet,j}] = 0$ за $j = 1, 2, \dots, S$.
- Нека първите M принципни компоненти на $\mathbf{X}^\top \mathbf{X} = \mathbf{C}(\mathbf{X}^\top) \in \mathbb{R}^{S \times S}$ са ортонормирани вектори $\mathbf{e}'_1, \mathbf{e}'_2, \dots, \mathbf{e}'_M \in \mathbb{R}^S$.
- Дефинираме матрицата $V_M = [\mathbf{e}'_1 \quad \mathbf{e}'_2 \quad \dots \quad \mathbf{e}'_M] \in \mathbb{R}^{S \times M}$.
- Проекцията на термовете в M -мерно пространство получаваме:
 $\bar{\mathbf{X}}_M = V_M^\top \mathbf{X}^\top \in \mathbb{R}^{M \times |V|}$. На всеки стълб (терм) в $\bar{\mathbf{X}}_M$ съпоставяме M -мерен вектор.

Singular Value Decomposition (SVD)

- Съществува по-директен алгебричен метод за декомпозиция на всяка правоъгълна матрица \mathbf{X} .
- Може да се покаже, че ненулевите собствени стойности на $\mathbf{X}^\top \mathbf{X}$ и $\mathbf{X} \mathbf{X}^\top$ съвпадат.
- Нека $\mathbf{X} \mathbf{X}^\top = U \Lambda U^\top$ и $\mathbf{X}^\top \mathbf{X} = V \Lambda V^\top$. Тогава (грубо):
$$\begin{aligned}\mathbf{X} \mathbf{X}^\top &= U \Lambda U^\top = U \sqrt{\Lambda} \sqrt{\Lambda} U^\top = \\ &= U \sqrt{\Lambda} V^\top V \sqrt{\Lambda} U^\top = (U \sqrt{\Lambda} V^\top)(U \sqrt{\Lambda} V^\top)^\top \implies \mathbf{X} = U \sqrt{\Lambda} V^\top\end{aligned}$$
- Ако се ограничим до най-големите M собствени стойности получаваме: $\mathbf{X}_M = U_M \sqrt{\Lambda_M} V_M^\top$.
- Матрицата \mathbf{X}_M е най-близката до \mathbf{X} спрямо Фробениус норма $\|A\| = \sqrt{\sum_{i=1}^N \sum_{j=1}^S A_{i,j}^2}$ с ранк $\leq M$
- Доказателствата за SVD може да се намерят в по-задълбочените учебници по линейна алгебра.
- От изчислителна гледна точка SVD е по-ефективен.

Латентен семантичен анализ (LSA) и латентно семантично индексиране (LSI)

- Използва се когато имаме матрица терм / документ
- Нека за терм / документ матрицата $\mathbf{X} \in \mathbb{R}^{|V| \times S}$ сме намерили декомпозиция $\mathbf{X} = U\sqrt{\Lambda}V^\top$ и сме я приближили в M -мерно пространство $\mathbf{X}_M = U_M\sqrt{\Lambda_M}V_M^\top$, където $\mathbf{X}_M \in \mathbb{R}^{|V| \times S}$, $U_M \in \mathbb{R}^{|V| \times M}$, $\Lambda_M \in \mathbb{R}^{M \times M}$, $V_M \in \mathbb{R}^{S \times M}$
- Нека ни е дадена заявка $q \in \mathbb{R}^{|V|}$. Дефинираме $q_M \in \mathbb{R}^M$ като $q_M = U_M^\top q$
- Намираме скаларното произведение (косинусова близост) на q_M с документите от колекцията като умножим $\tilde{\mathbf{X}}_M^\top q_m$, където $\tilde{\mathbf{X}}_M = U_M^\top \mathbf{X} \in \mathbb{R}^{M \times S}$
- По аналогичен начин можем да постъпваме с термовете.

План на лекцията

1. Формалности за курса (5 мин)
2. Интуиция за принципния компонентен анализ (10 мин)
3. Смятане с вектори и матрици (15 мин)
4. Свойства на ковариационната матрица (15 мин)
5. Задача за намиране на принципните компоненти (25 мин)
6. Влагане на думи и контексти в нискомерно гъсто векторно пространство и латентен семантичен анализ (10 мин)
- 7. Семантично пространствени релации (10 мин)**


Пример

две хубави очи душата на дете
в две хубави очи музика лъчи
не искат и не обещават те
душата ми се моли
дете
душата ми се моли
страсти и неволи
ще хвърлят утре върху тях
булoto на срам и грях

булoto на срам и грях
не ще го хвърлят върху тях
страсти и неволи
душата ми се моли
дете
душата ми се моли
не искат и не обещават те
две хубави очи музика лъчи
в две хубави очи душата на дете


Пример – проектираме в двумерно пространство

	p1	p2
дете	0.92	-0.50
две	2.76	-2.84
хубави	3.83	3.92
очи	3.30	-3.30
душата	1.58	1.29
на	0.79	-0.25
в	1.11	1.08
музика	1.22	1.24
лъчи	0.57	-0.58
не	0.09	0.09



Пример – нормализираме до единични вектори


	p1	p2	p3
дете	0.39	-0.21	0.90
две	0.67	-0.69	-0.26
хубави	0.69	0.70	-0.19
очи	0.71	-0.71	0.00
душата	0.53	0.44	0.72
на	0.34	-0.11	0.93
в	0.72	0.70	0.00
музика	0.70	0.71	0.00
лъчи	0.70	-0.71	0.00
не	0.70	0.71	0.00



Семантично пространствени релации

- Косинусовата близост следва да отговаря на семантична близост следствие на сходната дистрибуцията на термовете в контекстите.
- Пример:
 - Най-близките до **футбол**:
баскетбол, 0.9803
хандбал, 0.9626
топка, 0.9536
волейбол, 0.9527
телевизията, 0.9504
 - Най-близките до **гърция**:
румъния, 0.9921
българия, 0.9914
албания, 0.9897
хърватия, 0.9887
македония, 0.9860

Семантично пространствени релации



Заключение

- Чрез влагането на термовете в нискомерно гъсто семантично пространство се постига:
 - изчислителна ефективност,
 - подобряване на обхвата,
 - евентуално и подобряване на прецизността.
- Проблеми с методът на принципните компоненти:
 - сложно и изчислително скъпо намиране на принципните компоненти,
 - налага се актуализиране за да се отразят нови езикови феномени.